Librería de análisis de datos: Pandas

pandas

Pandas - Guía de referencia

Importar la librería

```
import pandas as pd
```

Series

Índice **Valores**

Las **Series** son una estructura de datos de 1 dimensión con índice asociado basado en etiquetas.

```
s = pd.Series(data, index, dtype, name, ...)
```

index= Valores tomados como índice de la serie.
dtype= Tipo de dato de la serie.
name= Nombre de la serie.

data= Contenido de la serie creada.

Con listas

```
pd.Series([1, 2, 3], index = ['a', 'b', 'c'])
```

Con diccionarios

```
pd.Series({'a' :  1, 'b' : 2, 'c': 3 })
```

a	1
b	2
c	3

dtype: int64

DataFrame

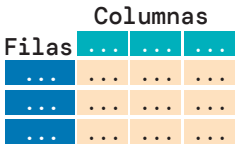

Los DataFrame son una estructura de datos de 2 dimensión con índices asociados a filas y columnas basado en etiquetas.

```
df = pd.DataFrame(data, index, columns, ...)
```

index= Valores tomados como índice de las filas.
columns= Valores tomados como índice de las columnas.

data= Contenido del **DataFrame** creado.

Con arreglos

```
pd.DataFrame([[1, 2], [3, 4]], columns= ['a', 'b'])
```

Con diccionarios

```
pd.DataFrame({ 'a' :  [1, 3], 'b' : [2, 4] })
```

	a	b
0	1	2
1	3	4

Combinación de datos

pd.concat([df_a, df_b])

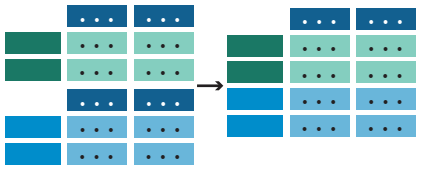

pd.concat([df_a, df_b], axis = 1)

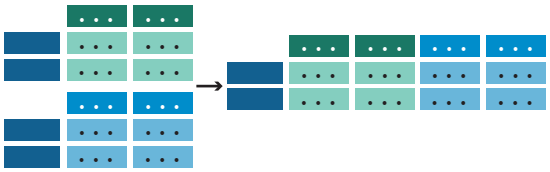

pd.join(df_a, df_b, how = ___)

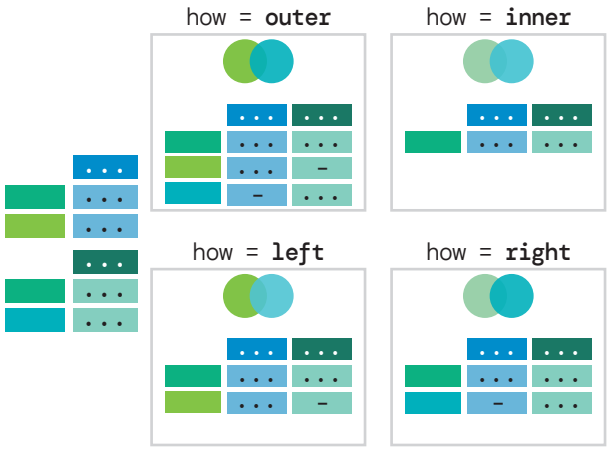

pd.merge(df_a, df_b, on = 'col', how = _)

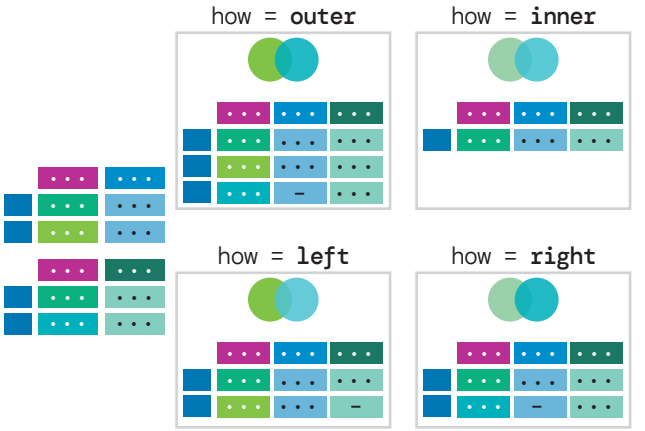

Agrupar datos

df.groupby('A').agg('B': function , 'C': function, ...)

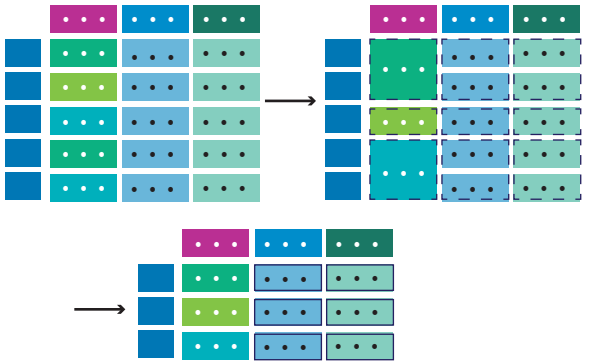

df.groupby('A').*

Funciones de agregación predefinidas.

- .first()
- .last()
- .sum()
- .prod()
- .size()
- .mean()

The pandas development team. (2020, 17 de Marzo). Pandas API reference (Versión 1.03) [software]. Consultado el 26 de mayo de 2020. https://pandas.pydata.org/docs/reference/index.html

Importar datos

pd.read*

```
pd.read_csv(ruta, ...)
pd.read_excel(ruta, ...)
pd.read_table(ruta, ...)
pd.read_json(ruta, ...)
pd.read_sql(query, conector, ...)
...
```

Exportar datos

df.to_*

```
df.to_csv(...)
df.to_excel(...)
df.to_latex(...)
df.to_json(...)
df.to_clipboard(...)
...
```

Selección por etiquetas

df.loc['id']	Fila con etiqueta 'id'.
df.loc['a' : 'f']	Elementos en las filas entre a y f.
df.loc[['a', 'c']]	Elementos en las fila a y c.
df.loc['i, 'col']	Elemento en la fila i y columna col.
df.loc[:, 'col']	Elementos en columna 'col.
df.at['x', 'y']	Elemento en la celda (x, y).

Visualizar datos

df.plot.*

df.plot.line(...)	Gráfica de líneas
df.plot.bar(...)	Gráfica de barras
df.plot.pie(...)	Gráfica circular
df.plot.hist(...)	Histograma
df.plot.box(...)	Diagrama de cajas
df.plot.scatter(...)	Diagrama de dispersión
df.plot.area(...)	Gráfica de áreas
df.plot.hexbin(...)	Gráfica hexagonal

Selección por posición

df.iloc[0]	Fila en la posición 0.
df.iloc[0 : 5]	Elementos en las filas entre 0 y 10.
df.iloc[[0, 1]]	Elementos en las fila 0 y 1.
df.iloc[0, 3]	Elemento en la fila 0 y columna 3.
df.iloc[:, 2]	Elementos en columna 2.
df.at[1, 2]	Elemento en la celda (1 , 2).

Selección condicional

Series (<, >, >=, <=, ==, !=) valor
Arreglo de booleanos usado para indexar.

df[df['col'] > 0]
Selección de filas que cumplan una condición

df[(df['col'] > 0) & (df['col'] < 100)]
Operaciones a nivel de bits (&, |, ~, ^)

df.where(df < 0, -df)
Reemplazar filas que cumplan la condición con el valor de la celda de otro DataFrame.

df.mask(df > 0, -df)
Reemplazar filas que **NO** cumplan la condición con el valor de la celda de otro DataFrame.

df.query('(a < b) & (b < c)')
Selección condicional con una sintaxis especial basada en nombres de columnas.

Selección de filas

df.head(n)	Selecciona las primeras n filas
df.tail(n)	Selecciona las últimas n filas
df.sample(n)	Selecciona n filas aleatorias
df.nsmallest(n, 'col')	Selecciona las n filas menores.
df.nlargest(n, 'col')	Selecciona las n filas mayores.

Describir datos

df['col'].min( )	Valor mínimo
df['col'].max( )	Valor máximo
df['col'].mean( )	Media aritmética
df['col'].mode( )	Moda
df['col'].median( )	Mediana
df['col'].std( )	Desviación estándar
df['col'].var( )	Varianza
df['col'].quantile(q)	Cuantil en posición q
df['col'].skew()	Asimetría
df['col'].kurt()	Curtosis
df['col'].corr()	Correlación
df.pivot_table(...)	Tablas de pivote
pd.crosstab(...)	Tabla de contingencia

Operaciones en objetos

df['col'] = 0	Asignar valores escalares
df['c'] = df['a'] + df['b']	Operadores entre objetos
df['col'] *= 1000	Asignación con operación
df.loc['max'] = df.max()	Asignación de filas
df.iloc[0:5, 0:5] = 3.5	Asignación de rangos
df[df['a'] < 0] = 0	Asignación condicional
df.at[0,0] = np.NaN	Asignación de celdas

Limpieza de datos

df.replace(...)	Reemplazar valores
df.drop_duplicates()	Eliminar filas repetidas
df.dropna()	Eliminar valores faltantes
df.fillna(valor)	Imputar valores faltantes
df.isna()	Filas con valores faltantes
df.notna()	Filas sin valores faltantes
df['col'].unique()	Valores únicos de la fila
df['col'].value_counts()	Conteo de valores por columna

Utilidades generales

df['col].idxmin()	Etiqueta del valor mínimo
df['col].idxmax()	Etiqueta del valor máximo
df.set_index(index)	Asignar un nuevo índice
df.reset_index()	Reiniciar el índice
df.astype(dtype)	Modificar tipo de dato
df.sort_values(by = "col")	Reordenar por valores de columna

The pandas development team. (2020, 17 de Marzo). Pandas API reference (Versión 1.03) [software].
Consultado el 26 de mayo de 2020. https://pandas.pydata.org/docs/reference/index.html